tidyr

Fundamentos lenguajes: R

Alberto Torres Barrán y Irene Rodríguez Luján

2019-12-15

Introducción

- El 80% del tiempo de un análisis se emplea limpiando y preparando los datos (Dasu y Johnson, 2003)
- Importados los datos, es importante estructurarlos para que el análisis sea lo más fácil posible
- Las librerías del tidyverse están construidas alrededor del concepto de datos ordenados o *tidy data*:
    - Cada variable forma una columna
    - Cada observación forma una fila
    - Cada tipo de observación forma una tabla
- Datos tabulares/rectangulares no implican datos ordenados!!

Formas de almacenamiento

Distintas formas de almacenar los mismos datos [R for Data Science]:

```
table1
## # A tibble: 6 x 4
##   country      year  cases population
##   <chr>       <int>  <int>      <int>
## 1 Afghanistan  1999    745   19987071
## 2 Afghanistan  2000   2666   20595360
## 3 Brazil       1999  37737  172006362
## 4 Brazil       2000  80488  174504898
## 5 China        1999 212258 1272915272
## 6 China        2000 213766 1280428583
```

```
table2
## # A tibble: 12 x 4
##    country      year type            count
##    <chr>       <int> <chr>           <int>
##  1 Afghanistan  1999 cases             745
##  2 Afghanistan  1999 population   19987071
##  3 Afghanistan  2000 cases            2666
##  4 Afghanistan  2000 population   20595360
##  5 Brazil       1999 cases           37737
##  6 Brazil       1999 population  172006362
##  7 Brazil       2000 cases           80488
##  8 Brazil       2000 population  174504898
##  9 China        1999 cases          212258
## 10 China        1999 population 1272915272
## 11 China        2000 cases          213766
## 12 China        2000 population 1280428583
```

```
table3
## # A tibble: 6 x 3
##   country      year rate
## * <chr>       <int> <chr>
## 1 Afghanistan  1999 745/19987071
## 2 Afghanistan  2000 2666/20595360
## 3 Brazil       1999 37737/172006362
## 4 Brazil       2000 80488/174504898
## 5 China        1999 212258/1272915272
## 6 China        2000 213766/1280428583
```

```
table4a
## # A tibble: 3 x 3
##   country     `1999` `2000`
## * <chr>        <int>  <int>
## 1 Afghanistan    745   2666
## 2 Brazil       37737  80488
## 3 China       212258 213766
```

```
table4b
## # A tibble: 3 x 3
##   country         `1999`     `2000`
## * <chr>            <int>      <int>
## 1 Afghanistan   19987071   20595360
## 2 Brazil       172006362  174504898
## 3 China       1272915272 1280428583
```

Formatos "ancho" y "largo"

wide

id	x	y	z
1	a	c	e
2	b	d	f

long

id	key	val
1	x	a
2	x	b
1	y	c
2	y	d
1	z	e
2	z	f

Fuente: https://github.com/gadenbuie/tidyexplain

Operaciones con datos ordenados

```
table1 %>%
  mutate(ratio = cases / population * 10000)
## # A tibble: 6 x 5
##   country      year  cases population ratio
##   <chr>       <int>  <int>      <int> <dbl>
## 1 Afghanistan  1999    745   19987071 0.373
## 2 Afghanistan  2000   2666   20595360 1.29
## 3 Brazil       1999  37737  172006362 2.19
## 4 Brazil       2000  80488  174504898 4.61
## 5 China        1999 212258 1272915272 1.67
## 6 China        2000 213766 1280428583 1.67
```

```
table1 %>%
  group_by(year) %>%
  summarize(total = sum(cases))
## # A tibble: 2 x 2
##    year  total
##   <int>  <int>
## 1  1999 250740
## 2  2000 296920
```

```
table1 %>%
  mutate(ratio = cases / population * 10000,
         year = as.character(year)) %>%
  ggplot(mapping = aes(x = country, y = ratio, fill = year)) +
    geom_bar(stat = "identity", position = "dodge")
```

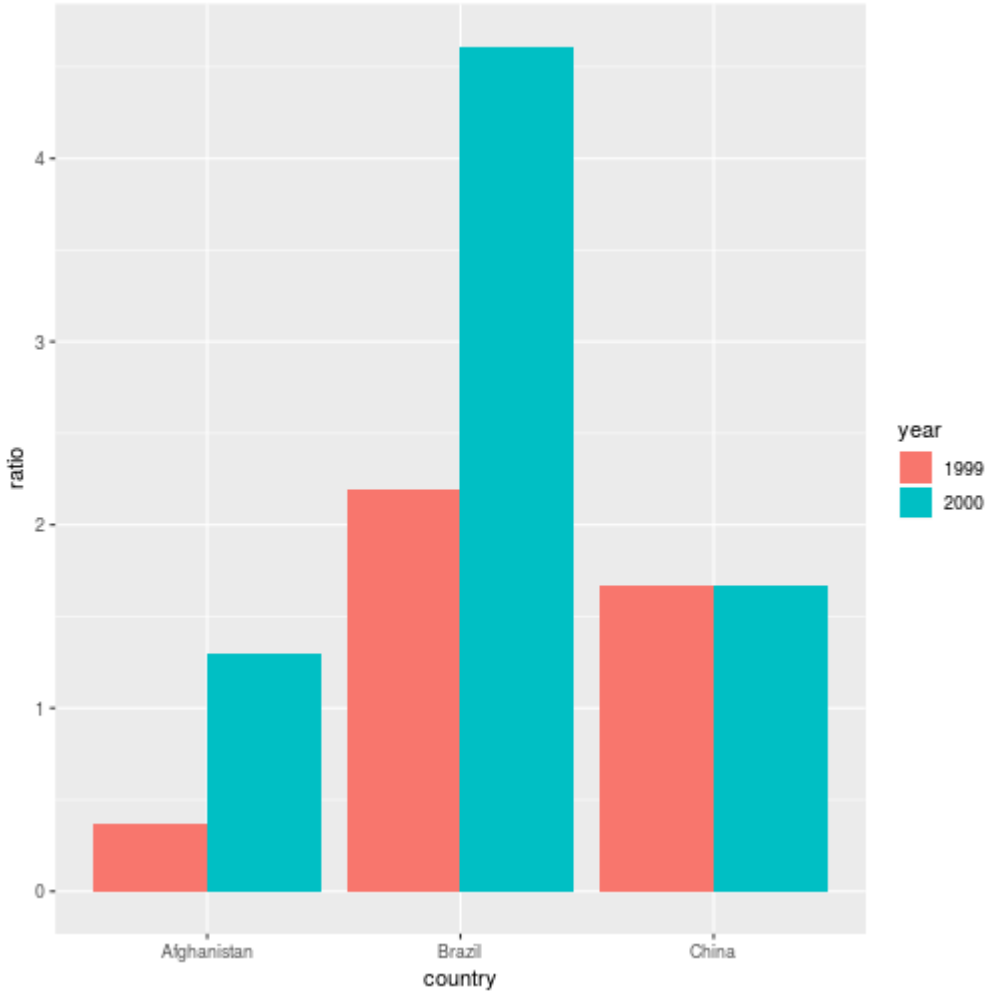

tidyr 1.0

- Desde la versión 1.0 de tidyr, se han creado versiones más potentes de las antiguas `spread` y `gather`
- En la siguiente tabla podemos ver la equivalencia:

pandas	tidyr <1.0	tidyr 1.0	data.table	reshape2
pivot	spread	pivot_wider	dcast	cast
melt	gather	pivot_longer	melt	melt

pivot_wider

```
head(table2)
## # A tibble: 6 x 4
##   country      year type           count
##   <chr>       <int> <chr>          <int>
## 1 Afghanistan  1999 cases            745
## 2 Afghanistan  1999 population  19987071
## 3 Afghanistan  2000 cases           2666
## 4 Afghanistan  2000 population  20595360
## 5 Brazil       1999 cases          37737
## 6 Brazil       1999 population 172006362
```

```
pivot_wider(table2, names_from = type, values_from = count)
## # A tibble: 6 x 4
##   country      year  cases population
##   <chr>       <int>  <int>      <int>
## 1 Afghanistan  1999    745   19987071
## 2 Afghanistan  2000   2666   20595360
## 3 Brazil       1999  37737  172006362
## 4 Brazil       2000  80488  174504898
## 5 China        1999 212258 1272915272
## 6 China        2000 213766 1280428583
```

pivot_longer

```
table4a
## # A tibble: 3 x 3
##   country     `1999` `2000`
## * <chr>        <int>  <int>
## 1 Afghanistan    745   2666
## 2 Brazil       37737  80488
## 3 China       212258 213766
```

```
pivot_longer(table4a, names_to = "year", values_to = "cases", -country)
## # A tibble: 6 x 3
##   country     year   cases
##   <chr>       <chr>  <int>
## 1 Afghanistan 1999     745
## 2 Afghanistan 2000    2666
## 3 Brazil      1999   37737
## 4 Brazil      2000   80488
## 5 China       1999  212258
## 6 China       2000  213766
```

Ejemplo

resp_id	age	airplane	anchorman	bridesmaids
1	48	TRUE	TRUE	TRUE
2	31	FALSE	TRUE	TRUE
3	30	FALSE	FALSE	FALSE

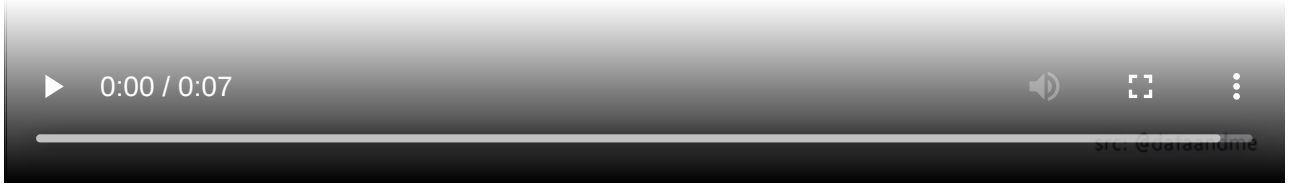

separate

```
table3
```

```
## # A tibble: 6 x 3
##   country      year rate
## * <chr>       <int> <chr>
## 1 Afghanistan  1999 745/19987071
## 2 Afghanistan  2000 2666/20595360
## 3 Brazil       1999 37737/172006362
## 4 Brazil       2000 80488/174504898
## 5 China        1999 212258/1272915272
## 6 China        2000 213766/1280428583
```

```
separate(table3, rate, into = c("cases", "population"), sep = "/")
```

```
## # A tibble: 6 x 4
##   country      year cases  population
##   <chr>       <int> <chr>  <chr>
## 1 Afghanistan  1999 745    19987071
## 2 Afghanistan  2000 2666   20595360
## 3 Brazil       1999 37737  172006362
## 4 Brazil       2000 80488  174504898
## 5 China        1999 212258 1272915272
## 6 China        2000 213766 1280428583
```

- Por defecto `separate()` mantiene el tipo de la columna en las nuevas

```
separate(table3, rate, into = c("cases", "population"), sep = "/", convert = TRUE)
## # A tibble: 6 x 4
##   country      year  cases population
##   <chr>       <int>  <int>      <int>
## 1 Afghanistan  1999    745   19987071
## 2 Afghanistan  2000   2666   20595360
## 3 Brazil       1999  37737  172006362
## 4 Brazil       2000  80488  174504898
## 5 China        1999 212258 1272915272
## 6 China        2000 213766 1280428583
```

unite

```
unite(mpg, make, manufacturer, model, sep = " ")
## # A tibble: 234 x 10
##    make          displ  year   cyl trans     drv     cty   hwy fl    class
##    <chr>         <dbl> <int> <int> <chr>     <chr> <int> <int> <chr> <chr>
##  1 audi a4         1.8  1999     4 auto(l5)  f        18    29 p     compa…
##  2 audi a4         1.8  1999     4 manual(m… f        21    29 p     compa…
##  3 audi a4         2    2008     4 manual(m… f        20    31 p     compa…
##  4 audi a4         2    2008     4 auto(av)  f        21    30 p     compa…
##  5 audi a4         2.8  1999     6 auto(l5)  f        16    26 p     compa…
##  6 audi a4         2.8  1999     6 manual(m… f        18    26 p     compa…
##  7 audi a4         3.1  2008     6 auto(av)  f        18    27 p     compa…
##  8 audi a4 quat…   1.8  1999     4 manual(m… 4        18    26 p     compa…
##  9 audi a4 quat…   1.8  1999     4 auto(l5)  4        16    25 p     compa…
## 10 audi a4 quat…   2    2008     4 manual(m… 4        20    28 p     compa…
## # … with 224 more rows
```

Otras funciones

tidyr también tiene otras funciones útiles para trabajar con `NA`s:

- `drop_na()`, elimina filas que tengan algún `NA`
- `fill()`, completa `NA`s con el valor anterior
- `replace_na()`, reemplaza `NA`s por un valor